

Perancangan Kontroler Tertanam Menggunakan Direct Neural Network untuk Pengaturan Level Tangki PCT-100

Muhammad Faris Zuhairi, Eka Iskandar, Trihastuti Agustinah

Departemen Teknik Elektro, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember (ITS)

Jl. Arief Rahman Hakim, Surabaya 60111

e-mail: zuhairimuhammadfaris@gmail.com, iskandar@elect-eng.its.ac.id, trihastuti@ee.its.ac.id

Abstrak—Level tangki PCT-100 memiliki karakteristik nonlinear akibat keluaran air drain valve. Kemampuan self learning kontroler dibutuhkan untuk mengatasi perubahan beban. Kontroler direct neural network dapat mengendalikan level dengan mengambil input error dan secara langsung mengirim output sinyal kontrol. Namun algoritma cerdas kontroler membutuhkan pemilihan nilai learning rate yang tepat agar didapat spesifikasi respon yang diinginkan. Spesifikasi ini berupa overshoot level kurang dari 10% dan settling time 5% kurang dari 200 detik saat pembebanan valve dan tracking set point. Rangkaian conditioning yang dibuat memberikan hasil linear dengan kesalahan pengukuran maksimal sebesar 121.6mV untuk pembacaan sensor dan 489mV untuk tegangan kontrol. Kontroler neural network dengan learning rate sebesar 10 memiliki hasil terbaik dari sampel uji learning rate konstan, mampu beradaptasi dengan beban motor drain valve dengan overshoot 12% dan settling time 161.7 detik. Adaptasi learning rate melalui parameter alpha juga dapat mengatasi perubahan beban drain terhadap error proses dengan model terbaik saat $\alpha=0.1$, dimana overshoot dan settling time masing-masing sebesar 3.8% dan 111.5 detik untuk simulasi serta 3.43% dan 127.2 detik untuk implementasi. Model neural network yang dibuat mampu melakukan tracking terhadap perubahan set point naik dan turun dengan overshoot dan undershoot yang semakin kecil untuk step setpoint selanjutnya.

Kata Kunci—PCT-100, Neural Network, Learning Rate, Sistem Tertanam

I. PENDAHULUAN

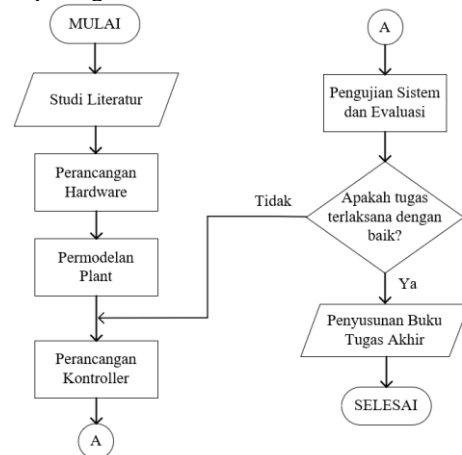
UMUMNYA industri proses banyak menerapkan sistem otomatisasi pengaturan fluida. Fluida dialirkan melalui pompa, laju massa dikendalikan oleh control valve, dan ketinggian level dibaca oleh level sensor. Pengaturan level fluida digunakan pada plant proses diantaranya tangki lube oil diesel, air ballast kapal, dan *freshwater* [1]. PCT-100 merupakan miniature sistem proses industry dengan fasilitas pengaturan variable level, flow, pressure, dan temperature [2]. Level plant dikendalikan melalui bukaan flow control valve memiliki karakteristik *time-varying* dan nonlinear yang seringkali mengalami perubahan parameter dalam kondisi-kondisi tertentu, seperti adanya beban air keluar [3]. Untuk mengatasi perubahan ini, diperlukan metode yang dapat belajar (*learning*) terhadap perubahan.

Algoritma neural network banyak digunakan pada berbagai bidang karena kemampuannya dalam memetakan sistem nonlinear dan *self-learning*. Selain itu, neural network dapat digunakan untuk permodelan dan pengendalian sistem kompleks yang terdapat noise pengukuran dan disturbance karena adanya karakteristik adaptif [4].

Penggunaan neural network memiliki keunggulan dapat beradaptasi terhadap perubahan model plant, namun pemilihan learning rate masih dilakukan manual dengan eksperimen sehingga apabila pemilihan kurang tepat memungkinkan terjadinya overshoot yang tinggi, ketidakstabilan, atau tidak dapat mengikuti set point yang diinginkan. Skema adaptasi dapat ditambahkan agar learning rate dapat menyesuaikan error level. Selain itu, motor flow control valve sebagai aktuator memiliki daya suplai tinggi (0-24V, 1A) dan tidak bisa dijalankan oleh modul *data actuation* yang tersedia. Pada tugas akhir ini akan dirancang kontroler tertanam neural network plant PCT-100 yang mampu menjaga performa terhadap pembebanan dan mampu melakukan tracking setpoint level untuk mendapat overshoot kurang dari 10% dan settling time 5% kurang dari 200 detik..

II. METODOLOGI

Tahapan penelitian yang dilakukan sesuai urutan flowchart pada gambar berikut.



Gambar 1. Flowchart Metodologi Penelitian

A. Permodelan Flow Control Valve

Flow control valve merupakan final element untuk mengendalikan flow fluida masuk menuju tangki. Model motor flow control valve didapatkan dengan metode identifikasi vitechkova orde 1 [5]. Model dari flow control valve dalam $\frac{m^3/s}{volt}$ diperoleh sebagai berikut.

$$G_{valve} = \frac{Q_{in}}{u} = \frac{2.6983 * 10^{-6}}{0.0034s + 1} e^{-0.0011s} \quad (2.1)$$

B. Permodelan Level Tangki

Sistem level tangki tunggal memenuhi hukum kesetimbangan massa, dimana flow masuk sama dengan flow keluar.

$$A_{tabung} \dot{h}(t) = Q_{in}(t) - Q_{out}(t) \quad (2.2)$$

Berdasarkan hukum bernoulli, air keluar dapat dinyatakan sebagai fungsi ketinggian h dan luas bukaan valve A_o .

$$Q_{out}(t) = A_o \sqrt{2gh(t)} \quad (2.3)$$

Model level dalam $\frac{m}{m^3/s}$ dapat disederhanakan menjadi sistem orde 1 sebagai berikut.

$$G_{level} = \frac{h}{Q_{in}} = \frac{b}{s+a} \quad (2.4)$$

Dimana


$$b = \frac{1}{A_{tabung}} = 49.7359$$

$$a(t) = \frac{A_o \sqrt{2g}}{A_{tabung} \sqrt{h}} = 220.3026 \frac{A_o}{\sqrt{h}}$$

Pole fungsi alih menunjukkan model level merupakan model nonlinear [3].

C. Sistem Pengaturan Level

Prinsip pengaturan level air dalam tangki PCT-100 ialah mengendalikan bukaan motor flow control valve untuk mengatur besarnya debit air yang masuk ke dalam tangki. Beban berupa air keluar pada drain valve akan memengaruhi level air dan harus dikontrol oleh kontroler direct neural network. Kontroler ini mendapat input error dan memberikan sinyal kontrol bukaan motor flow valve. Blok diagram closed loop tersaji pada gambar berikut.




Gambar 2. Diagram Blok Closed Loop

D. Perancangan Kontroler Neural Network

Struktur neural network untuk kontroler memiliki 1 input layer, 1 hidden layer, dan 1 output layer. Input neuron menggunakan sinyal error level sebanyak 3 node yang diasumsikan kontroler menyerupai PID konvensional (shifting hingga z^{-2} dalam domain diskrit). Input neural network dapat dituliskan sebagai berikut.

$$x_i = [e(k), e(k-1), e(k-2)] \quad (2.4)$$

Berikut merupakan struktur neural network kontroler yang dirancang.



Gambar 3. Struktur Direct Control Neural Network

Pada propagasi maju, output hidden layer j merupakan

fungsi aktivasi dari jumlahan bobot neuron sebelumnya dan dapat dirumuskan sebagai berikut [6].

$$h_j = \frac{1}{1 + e^{-s_j}} \quad (2.5)$$

$$s_j = \sum_{i=1}^t w_{ji} x_i$$

Dengan cara yang sama keluaran neuron output layer sebagai sinyal kontrol dapat ditentukan.

$$u = \frac{1}{1 + e^{-r}} \quad (2.6)$$

$$r = \sum_{j=1}^t v_j h_j$$

Proses learning neural network akan meminimalisasi cost function berupa integral square error.

$$E(t) = \frac{1}{2} \sum_{k=1}^t e_y(k)^2 \quad (2.7)$$

$$e_y = y_{ref} - y$$

Minimisasi cost dilakukan terhadap weight w_{ji} dan v_j . Menggunakan aturan rantai diperoleh minimisasi cost function terhadap weight output [7]

$$\frac{\partial E(t)}{\partial v_j} = \frac{\partial E(t)}{\partial e_y} \frac{\partial e_y}{\partial e_u} \frac{\partial e_u}{\partial u(t)} \frac{\partial u(t)}{\partial r} \frac{\partial r}{\partial v_j}$$

Local gradien output layer ditentukan sebagai δ^1

$$\delta^1 = \frac{\partial E(t)}{\partial e_y} \frac{\partial e_y}{\partial e_u} \frac{\partial e_u}{\partial u(t)} \frac{\partial r}{\partial v_j} \frac{\partial u(t)}{\partial r}$$

$$\delta^1 = e_y u(t) [1 - u(t)] \quad (2.5)$$

$$\frac{\partial E(t)}{\partial v_j} = -\delta^1 * h_j * \frac{\partial e_y}{\partial e_u} \quad (2.6)$$

Updating weight v_j :

$$\Delta v_j = -\eta * \frac{\partial E(t)}{\partial v_j} \quad (2.5)$$

$$v_j(t+1) = v_j(t) + \eta \text{sign} \left(\frac{\partial e_y}{\partial e_u} \right) \delta^1 h_j \quad (2.6)$$

Dengan menggunakan cara yang sama, diperoleh minimisasi cost function terhadap weight hidden.

$$\frac{\partial E(t)}{\partial w_{ji}} = -\delta^1 v_j h_j (1 - h_j) x_i \frac{\partial e_y}{\partial e_u}$$

Local gradient hidden layer ditentukan sebagai δ^2

$$\delta_j^2 = \delta^1 v_j h_j (1 - h_j) \quad (2.7)$$

$$\frac{\partial E(t)}{\partial w_{ji}} = -\delta_j^2 x_i \frac{\partial e_y}{\partial e_u} \quad (2.8)$$

Updating weight w_{ji} :

$$\Delta w_{ji} = \eta * \frac{\partial E(t)}{\partial w_{ji}} \quad (2.9)$$

$$w_{ji}(t+1) = w_{ji}(t) + \eta \text{sign} \left(\frac{\partial e_y}{\partial e_u} \right) \delta_j^2 x_i \quad (2.10)$$

Learning rate selain dapat diperoleh melalui metode eksperimental, dapat pula dibuat dinamis sesuai nilai error melalui self tuning [8]. Adaptif learning rate seperti ini dapat dirumuskan sebagai persamaan berikut.


$$\eta' = \eta + \alpha e_y \quad (2.11)$$

Learning rate η awal dapat digunakan sangat kecil dan α dapat dipilih berdasarkan eksperimen tanpa ada masalah. Indeks performansi kontroler dapat dihitung menggunakan *Mean Square Error* (MSE) yang cocok digunakan untuk sistem orde rendah. Kelebihan dari indeks performansi MSE yakni mudah dihitung secara matematis dan biasanya diterapkan untuk masukan unit step.

$$MSE = \frac{1}{n} \sum_{t=0}^n e^2(t) \quad (2.12)$$

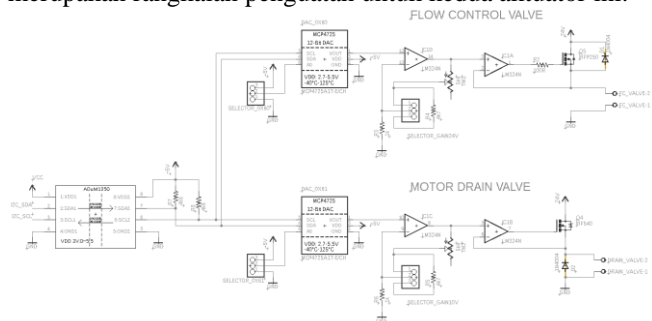
E. Perancangan Hardware Tertanam

Mikrokontroler merupakan unit pemrosesan digital untuk melaksanakan suatu tugas spesifik dalam sistem tertanam. Mikrokontroler STM32F407VGT6 melaksanakan fungsi pembacaan sensor dengan ADC dan memberikan sinyal kontrol ke aktuator. Berikut merupakan rancangan mikrokontroler dan modul komunikasi dengan PC.



Gambar 4. Rancangan Prototype Kontroler Tertanam

Pembacaan tegangan sensor 0-10V perlu diturunkan melalui rangkaian voltage divider agar dapat terukur ADC STM32 (0-3.3V). Modul *power electronic* sebagai rangkaian analog output berupa motor flow control valve dan motor drain valve menggunakan modul DAC MCP4725 yang dikuatkan oleh opamp dan MOSFET regulator. Berikut merupakan rangkaian penguatan untuk kedua aktuator ini.



Gambar 5. Rangkaian Analog Output


F. Skenario Pengujian Kontroler

Pengujian kontroler dilakukan pada software Simulink dan implementasi pada plant langsung. Spesifikasi respon yang diinginkan yakni overshoot kurang dari 10% dan settling time 5% kurang dari 200 detik. Kondisi nominal yang digunakan pada tahap pengujian diantaranya:

- Masukin flow rate Q_{in} : 0 – 3 lt/min
- Tegangan pompa konstan 10VDC


- Range tegangan motor flow valve : 12VDC (full closed) – 22VDC (full open)
- Batas runtime sistem : 1680 detik
- Timesampling : 100ms
- Learning rate awal : 10^{-5}
- Set point level statis : 100mm
- Pembebanan nominal : hanya manual drain valve terbuka (full open)

Sedangkan untuk kondisi pembebanan, divariasikan luas bukaan valve secara acak dengan periode 15 detik seperti pada diagram sekuen. Periode ini mampu memberikan simpangan hingga 20mm atau minimum 10% level tangki yang dapat dijangkau



Gambar 6. Sekuen Beban Luas Aperture Motor Drain Valve

Untuk kondisi tracking, divariasikan set point dengan step 50mm naik dan turun seperti kurva sinyal tracking berikut.




Gambar 7. Sekuen Setpoint untuk Pengujian Tracking

III. PENGUJIAN KONTROLER

Pengujian kontroler meliputi pengujian hardware dan algoritma program. Pengujian hardware meliputi pembacaan sensor (analog input) dan rangkaian *power electronics* (analog output). Sedangkan pengujian algoritma kontrol meliputi pengujian berbeban tanpa kontroler, kontroler dengan learning rate konstan, kontroler dengan adaptasi learning rate adaptif untuk set point konstan dan tracking.

A. Pengujian Pembacaan Sensor

Pengujian ini dilakukan dengan memberi tegangan referensi dari modul DAQ terkalibrasi ke 2 pin ADC STM32 (AI), yakni sensor flow dan level. Sinyal uji yang digunakan ialah ramp dengan pola naik lalu turun seperti Gambar 8.




Gambar 8. Pembacaan Analog Input Sinyal Referensi Ramp

Bentuk linier diperoleh karena tegangan masukan ADC diturunkan menggunakan resistor yang memiliki karakteristik beban linier. Simpangan tersebut dianggap tidak memengaruhi pembacaan sensor karena sangat kecil bila dibandingkan range sinyal maksimal yang dapat dibaca, yakni 10V. Simpangan maksimum ADC diperoleh sebesar 121.6mV.

B. Pengujian Power Electronics

Rangkaian analog output (AO) yang telah dibuat diuji dengan memberikan tegangan ramp ke pin analog input modul DAQ terkalibrasi. Gambar berikut menunjukkan respon linier tegangan kontrol yang diberikan.




Gambar 9. Pembacaan Sinyal Kontrol Motor Drain Valve


Simpangan maksimum terhadap pembacaan AI DAQ diperoleh sebesar 489mV untuk rangkaian penguatan flow control valve dan 200mV untuk rangkaian penguatan drain valve. Bentuk linier pada sinyal ramp uji diakibatkan oleh penguatan non-inverting operational amplifier yang merupakan nilai scalar konstan karena merupakan susunan resistor. Dengan penambahan rangkaian voltage follower, sinyal yang dikuatkan menuju beban akan dikoreksi oleh feedback yang berasal dari tegangan source MOSFET.

C. Pengujian Berbeban tanpa Kontroler

Pengujian ini menunjukkan bahwa respon level dipengaruhi oleh beban bukaan valve dan tidak bisa mencapai referensi set point. Respon level yang diperoleh tidak stabil, membuktikan bahwa perlu adanya kontroler agar set point dapat dicapai seperti ditunjukkan gambar berikut.




Gambar 10. Respon Level tanpa Kontroler



Gambar 11. Respon Tracking Level Tanpa Kontroler

D. Pengujian Berbeban dengan Set Point dan Learning Rate Konstan

Pengujian ini bertujuan untuk mengetahui pengaruh pembebanan terhadap variasi learning rate dengan menggunakan set point level tetap sebesar 100mm. Variasi diberikan dengan peningkatan seper-sepuluh, yaitu 0.001, 0.01, 0.1, 1, 2, 5, dan 10. Berikut merupakan hasil simulasi model neural network pada kondisi berbeban dengan variasi learning rate.



Gambar 12. Respon Pembebanan dengan Learning Rate Konstan

Tabel 1. Spesifikasi Respon Pembebanan terhadap Variasi Learning Rate


No.	Learning rate	Overshoot (mm)	% overshoot	Settling time (detik)	MSE
1	0.001	127.146	27.146	-	418.6203
2	0.01	125.369	25.369	1182.73	284.051
3	0.1	119.713	19.713	1171.63	225.1403
4	1	115.926	15.926	262.484	205.719
5	2	114.858	14.858	215.134	199.6002
6	5	113.181	13.181	174.074	195.106
7	10	112.025	12.025	161.709	195.3809

Pada pengujian berbeban dan variasi learning rate konstan, diperoleh hasil bahwa learning rate kurang dari 1 memiliki MSE yang tinggi. Pada kondisi ini respon level mengalami *underfitting*, yakni kejadian dimana model neural network tidak mempelajari hubungan variabel dalam data dengan baik sehingga beban valve memengaruhi respon level yang tidak menuju set point (Gambar 12). *Underfitting* ini disebabkan oleh learning rate yang kecil sehingga model tidak dapat melakukan *update weight* dengan cepat. Perubahan weight yang lama menyebabkan settling time 5% kurang dari 200 detik tidak dapat tercapai.

Model yang mengikuti set point ialah neural network dengan learning rate 1, 2, 5, dan 10, tetapi masih terdapat overshoot 12% hingga 16%. Model neural network dengan learning rate sebesar 10 merupakan model terbaik pada pengujian ini, dimana memiliki persen overshoot, settling time, dan MSE terkecil tetapi masih tidak dapat memenuhi tujuan overshoot kurang dari 10%. Oleh sebab itu, Langkah penentuan learning rate dengan cara eksperimental seperti ini beresiko terjadi *underfitting*, yakni model tidak dapat mengatasi efek pembebanan untuk mencapai setpoint yang diinginkan.

E. Pengujian Berbeban Kontroler dengan Set Point Konstan dan Adaptasi Learning Rate

Pengujian ini bertujuan untuk mengetahui pengaruh adaptasi learning rate menggunakan parameter alpha pada set point konstan 100mm. Variasi alpha diuji masing-masing sebesar 0.0001, 0.001, 0.01, 0.1, dan 1. Respon hasil pengujian tampak pada gambar dan tabel di bawah.



Gambar 13. Respon Pembebanan dengan Adaptasi Learning Rate


Tabel 2. Spesifikasi Setpoint Konstan pada Simulasi

No.	Alpha	Overshoot (mm)	% Overshoot	Settling time (detik)	MSE
1	0.0001	118.202	18.202	279.577	213.867
2	0.001	114.57	14.57	179.474	197.0926
3	0.01	106.187	6.187	129.898	192.8207
4	0.1	103.799	3.799	111.515	190.3915
5	1	102.389	2.389	111.415	167.3385

Tabel 3. Spesifikasi Setpoint Konstan pada Implementasi


No.	Alpha	Overshoot (mm)	% Overshoot	Settling time (detik)	MSE
1	0.0001	123.229	23.229	217.298	366.1553
2	0.001	107.104	7.104	232.902	401.0214
3	0.01	105.522	5.22	194.019	402.2102
4	0.1	103.426	3.426	127.213	377.8364
5	1	106.029	6.029	194.676	434.804

Pada pengujian variasi alpha ini, respon level memiliki karakteristik penurunan overshoot apabila alpha dinaikkan. Hal ini disebabkan alpha memengaruhi adaptasi learning rate, berupa penambahan atau pengurangan sebanding dengan error. Learning rate yang tinggi menyebabkan model neural network sangat adaptif dan *learning* berlangsung cepat. Proses *learning* yang terlalu cepat ini menyebabkan respon level stabil terhadap beban air keluar akibat *updating weight* yang cepat pula. Perubahan *weight* yang cepat juga menyebabkan keluaran neuron output layer berubah-ubah secara signifikan. Hal ini tampak pada sinyal keluaran kontroler, yakni sinyal kontrol motor flow valve yang memiliki pertambahan periode osilasi seiring peningkatan alpha. Kejadian ini dinamakan *overfitting*, yakni model melakukan *learning* terlalu baik dengan learning rate yang besar. Akurasi model dari fungsi aktivasi sigmoid berbanding lurus dengan peningkatan learning rate [9]. Meskipun sudah memenuhi overshoot kurang dari 10% dan MSE yang rendah pada sinyal uji, osilasi sinyal kontrol dalam prakteknya dihindari karena berpotensi merusak aktuatur. Gambar di bawah menunjukkan sinyal kontrol keluaran dari model neural network.



Gambar 14. Respon Simulasi Sinyal Kontrol pada Variasi Alpha


Pada $\alpha < 1$, tampak bahwa semakin besar alpha menyebabkan overshoot, settling time 5%, dan MSE menurun. Model neural network terbaik dalam pengujian ini ialah $\alpha = 0.1$ dimana overshoot dicapai sebesar 3.8%, settling time 111.5 detik untuk simulasi dan $\alpha = 0.1$ dengan overshoot 3.4%, settling time 127.2 detik untuk implementasi. Langkah eksperimental pemilihan alpha sebaiknya dimulai dari $\alpha < 1$ dan berangsur-angsur turun dengan melihat persen overshoot. Langkah penurunan sepersepuluh seperti pada pengujian ini dapat digunakan karena pergerakan pola overshoot, settling time, dan MSE dapat lebih terlihat. Selain itu, nilai alpha menunjukkan laju perubahan learning rate per satuan error proses. Sebagai contoh $\alpha = 0.1$ menunjukkan perubahan learning rate sebesar 0.1 per satu satuan error (dalam volt) pada setiap iterasi, yakni 100ms.



Gambar 15. Respon Undershoot Beban dengan Adaptasi Lr

F. Pengujian Berbeban terhadap Tracking Set Point

Pengujian ini bertujuan untuk mengetahui respon sistem bila diberikan perubahan step sinyal set point. Pola yang dicoba ialah kenaikan dan penurunan sebesar 50mm. Pengujian ini meliputi pengujian tracking terhadap variasi learning rate konstan dan learning rate adaptif (berubah). Respon hasil pengujian tampak pada gambar dan tabel di bawah.



Gambar 16. Respon Tracking dengan Adaptasi Learning Rate

Tabel 4. Spesifikasi Tracking pada Simulasi


No.	Alpha	Step Pertama (50mm)			Step Kedua (100mm)	
		Overshoot		t_s (5%)	Overshoot	
		(mm)	(%)	(detik)	(mm)	(%)
1	0.0001	-	-	-	110.85	10.86
2	0.001	60.76	21.52	202.74	104.03	4.03
3	0.01	57.6	15.19	82.03	101.54	1.54
4	0.1	54.38	8.76	58.57	100.93	0.93
5	1	52.61	5.21	52.91	100.26	0.26

Tabel 5. Spesifikasi Tracking pada Implementasi

No.	Alpha	Step Pertama (50mm)			Step Kedua (100mm)	
		Overshoot		t_s (5%) (detik)	Overshoot	
		(mm)	(%)		(mm)	(%)
1	0.0001	75.68	51.36	-	106.19	6.19
2	0.001	70.49	41	236	103.82	3.82
3	0.01	69.38	38.77	179.8	102.69	2.69
4	0.1	68.55	37.1	151.63	102	2.05
5	1	68.36	36.73	146.7	103.53	3.53

Berdasarkan tabel spesifikasi setpoint step pertama 50mm tersebut, semakin besar alpha berakibat penurunan persen overshoot dan settling time. Overshoot ini akan mengecil pada step setpoint level berikutnya karena model neural network sudah mengambil pola kenaikan pada tracking sinyal step sebelumnya. Penggunaan metode adaptasi learning rate tidak menghasilkan adanya kegagalan tracking, karena learning rate terus diupdate agar perubahan *weight* neuron juga semakin cepat. Namun, parameter adaptasi alpha yang kecil, seperti $\alpha=0.0001$ tidak dapat mencapai set point pada step pertama 50mm. Hal ini disebabkan model neural network melakukan *update weight* dengan lambat. Pada kondisi penurunan setpoint, kesemua model dengan variasi alpha mampu mengikuti setpoint dengan undershoot yang sangat kecil.

Dalam menentukan nilai alpha terbaik, perlu ditinjau apakah model neural network dengan variasi alpha mengalami *overfitting* atau tidak. Kejadian *overfitting* dapat dijumpai saat hasil learning sangat baik namun mengalami osilasi keluaran neuron output layer. Hal ini menyebabkan sinyal kontrol berubah naik turun secara sinusoidal.



Gambar 17. Respon Simulasi Sinyal Kontrol pada Variasi Alpha

Model terbaik untuk mendapat persen overshoot terkecil dengan osilasi kecil yakni $\alpha=0.1$. Pada simulasi, model ini memiliki overshoot 8.764% pada step tracking pertama dan menurun menjadi 0.932% pada step kedua. Pada Implementasi, terjadi overshoot 37.1% dan menurun 2.05%.

IV. KESIMPULAN

Modul ADC dari kontroler tertanam memberikan hasil yang linear dengan kesalahan pengukuran maksimal sebesar 121.6mV. Modul analog output untuk motor flow valve dan motor drain valve memiliki karakteristik linier dengan kesalahan masing-masing 489mV dan 200mV. Pengujian tanpa kontroler menunjukkan respon level dipengaruhi oleh beban motor drain valve dan tidak dapat mencapai set point. Model neural network dengan learning rate konstan dapat

mengatasi perubahan beban drain tetapi pemilihan learning rate melalui eksperimen beresiko terjadi underfitting, yakni model tidak dapat mempelajari hubungan variabel dengan baik. Adaptasi learning rate melalui parameter alpha dapat mengatasi perubahan beban drain terhadap error proses dengan model terbaik saat $\alpha=0.1$, dimana overshoot dan settling time masing-masing sebesar 3.8% dan 111.5 detik untuk simulasi serta 3.43% dan 127.2 detik untuk implementasi. Kejadian overfitting terjadi pada saat $\alpha \geq 1$ yang menyebabkan sinyal kontrol motor valve berosilasi dan dihindari karena beresiko merusak aktuatur. Model neural network mampu melakukan tracking terhadap perubahan set point naik dan turun dengan overshoot dan undershoot yang semakin kecil untuk step set point selanjutnya.

DAFTAR PUSTAKA

- [1] J. Zhao, X. Zhang, Y. Chen, and P. Wang, "Using sine function-based nonlinear feedback to control water tank level," *Energies (Basel)*, vol. 14, no. 22, Nov. 2021, doi: 10.3390/en14227602.
- [2] Bytronic, "Process Control Technology PCT-100 Datasheet," 2015. Accessed: Dec. 11, 2022. [Online]. Available: <http://www.bytronic.net/wp-content/uploads/2015/04/PCT100-PL0214.pdf>
- [3] M. Short and A. A. Selvakumar, "Non-Linear Tank Level Control for Industrial Applications," *Appl Math (Irvine)*, vol. 11, no. 09, pp. 876–889, 2020, doi: 10.4236/am.2020.119057.
- [4] X. Zong-Yi, G. Qiang, J. Li-Min, and W. Ying-Ying, "Modelling and Identification of Electrohydraulic System and Its Application," *IFAC Proceedings Volumes*, vol. 41, no. 2, pp. 6446–6451, Jan. 2008, doi: 10.3182/20080706-5-KR-1001.01087.
- [5] I. P. Jakoubek, "Experimental Identification of Stable Nonoscillatory Systems from Step-Responses by Selected Methods."
- [6] S. S. Haykin, *Neural networks and learning machines*. Prentice Hall/Pearson, 2009.
- [7] R. Hernández-Alvarado, L. G. García-Valdivinos, T. Salgado-Jiménez, A. Gómez-Espinosa, and F. Fonseca-Navarro, "Neural network-based self-tuning PID control for underwater vehicles," *Sensors (Switzerland)*, vol. 16, no. 9, Sep. 2016, doi: 10.3390/s16091429.
- [8] A. N. Ponce, A. A. Behar, A. O. Hernández, and V. R. Sitar, "Neural Networks for Self-tuning Control Systems," *Acta Polytechnica*, vol. 44, pp. 49–52, 2004, [Online]. Available: <http://ctn.cvut.cz/ap/>
- [9] H. Li, J. Li, X. Guan, B. Liang, Y. Lai, and X. Luo, "Research on Overfitting of Deep Learning," in *Proceedings - 2019 15th International Conference on Computational Intelligence and Security, CIS 2019*, Institute of Electrical and Electronics Engineers Inc., Dec. 2019, pp. 78–81. doi: 10.1109/CIS.2019.00025.