

# Perancangan Kontroller Tertanam Menggunakan Direct Neural Network Pada Pengaturan Level PCT-100

Muhammad Faris Zuhairi, Eka Iskandar, Trihastuti Agustinah

Departemen Teknik Elektro, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember (ITS)

Jl. Arief Rahman Hakim, Surabaya 60111

e-mail: faris.19071@mhs.its.ac.id

**Abstrak**—Pengaturan level tangki PCT-100 memiliki karakteristik nonlinear yang disebabkan oleh bukaan motor drain valve. Kontroller dengan kemampuan self learning diperlukan untuk mengatasi terjadinya perubahan beban. Direct neural network dapat mengendalikan level nonlinear melalui input error dan output sinyal kontrol. Spesifikasi respon level diharapkan memiliki overshoot < 10% dan settling time 5% kurang dari 90 detik. Selain itu, digunakannya kontroller tertanam dapat menyelesaikan permasalahan suplai daya tinggi pada flow control valve. Rangkaian ADC yang telah dibuat mampu membaca tegangan secara linier dengan kesalahan pembacaan maksimal 121.6mV. Sedangkan rangkaian controlling device mampu mengontrol flow control valve secara linier dengan kesalahan maksimal 489mV. Pengujian tanpa kontroller menunjukkan respon level dipengaruhi oleh bukaan drain valve sehingga level tidak bisa mencapai set point. Kontroller direct NN dengan learning rate 5 mampu beradaptasi dari pembebanan dengan overshoot 7.408%, tetapi memiliki settling time 5% 97.6714 detik. Kontroller direct NN dengan adaptasi learning rate  $\alpha=0.01$  mampu beradaptasi terhadap pembebanan dengan overshoot 4.523% dan settling time 89.375 detik sesuai spesifikasi respon yang diinginkan. Penggunaan metode eksperimental cukup menyulitkan karena harus menjalankan model sistem berulang kali. Hal ini diperbaiki dengan adaptasi learning rate melalui parameter  $\alpha$  untuk mendapat respon yang diinginkan dengan cepat.

**Kata Kunci**—PCT-100, Neural Network, Sistem Tertanam

## I. PENDAHULUAN

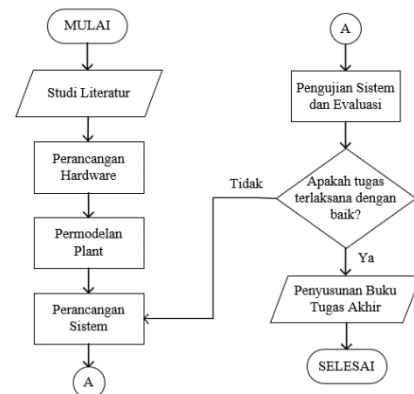
UMUMNYA industry proses banyak menerapkan sistem otomatisasi pengaturan fluida. Fluida dialirkan melalui pompa, laju massa dikendalikan oleh control valve, dan ketinggian level dibaca oleh level sensor. PCT-100 merupakan miniature sistem proses industry dengan fasilitas pengaturan variable level, flow, pressure, dan temperature [1]. Level plant dikendalikan melalui bukaan flow control valve. Namun level air dalam tangki PCT-100 merupakan sistem nonlinear karena mengalami perubahan parameter akibat beban bukaan drain valve (air keluar) [2]. Selain itu, motor flow control valve merupakan actuator dengan suplai daya kontrol yang besar, sehingga memerlukan rangkaian penguatan.

Salah satu metode learning yang menggunakan algoritma cerdas ialah neural network. Algoritma ini dapat mempelajari perubahan beban pada plant dan akan otomatis melakukan updating bobot selama plant beroperasi sehingga mudah memenuhi spesifikasi kontrol yang diinginkan. Dengan struktur direct, kontroller dapat langsung memberikan sinyal

kontrol sesuai berdasar error setpoint variable sistem yang dikendalikan. Namun, pemilihan learning rate (Lr) pada propagasi balik masih perlu dilakukan manual berdasar hasil eksperimen, sehingga jika kurang tepat memungkinkan terjadinya overshoot level. Skema self tuning dapat ditambahkan agar learning rate dapat beradaptasi sesuai error level. Pada tugas akhir ini akan dirancang controller tertanam menggunakan direct neural network plant PCT-100 yang mampu mengatasi masalah nonlinearity, pemilihan learning rate, dan penguatan sinyal actuator untuk mendapat overshoot kurang dari 10% dan settling time 5% kurang dari 90 detik..

## II. METODOLOGI

Tahapan penelitian yang dilakukan sesuai urutan flowchart pada gambar Berikut.



Gambar 1. Flowchart Metode Penelitian

### A. Permodelan Flow Control Valve

Flow control valve merupakan final element untuk mengendalikan flow fluida masuk menuju tangki. Model flow control valve didapatkan dengan metode identifikasi vitechkova orde 1 [3]. Model dari flow control valve diperoleh sebagai Berikut.

$$G_{valve} = \frac{Q_{in}}{u} = \frac{0.1619}{0.0034s + 1} e^{-0.0011s} \quad (2.1)$$

### B. Permodelan Level Tangki

Sistem level tangki tunggal memenuhi hukum kesetimbangan massa, dimana flow masuk sama dengan flow keluar.

$$A_{tabung} \dot{h}(t) = Q_{in}(t) - Q_{out}(t) \quad (2.2)$$

Berdasarkan hukum Bernoulli, air keluar dapat dinyatakan sebagai fungsi ketinggian h dan luas bukaan valve  $A_0$ .

$$Q_{out}(t) = A_o \sqrt{2gh(t)} \quad (2.3)$$

Model level dapat disederhanakan menjadi sistem orde 1 sebagai Berikut.

$$G_{level} = \frac{h}{Q_{in}} = \frac{b}{s + a} \quad (2.4)$$

Dimana

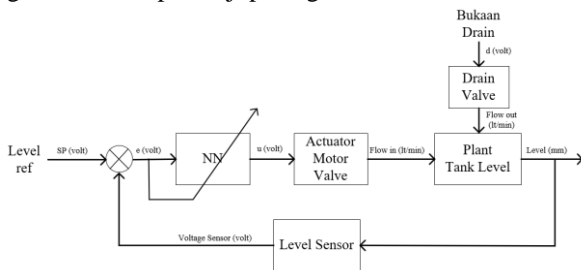
$$b = \frac{1}{A_{tabung}} = 3.93 * 10^{-5}$$

$$a(t) = \frac{A_o \sqrt{2g}}{A_{tabung} \sqrt{h}} = 1.74 * 10^{-4} * \left( \frac{A_o}{\sqrt{h}} \right)$$

Pole transfer function menunjukkan model level merupakan model nonlinear [2].

### C. Sistem Pengaturan Level

Prinsip pengaturan level air dalam tangki PCT-100 ialah mengendalikan bukaan motor flow control valve untuk mengatur besarnya debit air yang masuk ke dalam tangki. Beban berupa air keluar pada drain valve akan memengaruhi level air dan harus dikontrol oleh kontroller direct neural network. Kontroller ini mendapat input error dan memberikan sinyal kontrol bukaan motor flow valve. Blok diagram closeloop tersaji pada gambar berikut.




Gambar 2. Diagram Blok Closed Loop

### D. Perancangan Kontroller Neural Network

Struktur neural network untuk kontroller memiliki 1 input layer, 1 hidden layer, dan 1 output layer. Input neuron menggunakan sinyal error level sebanyak 3 node yang diasumsikan kontroller menyerupai PID konvensional (shifting hingga  $z^{-2}$  dalam domain diskrit). Input neural network dapat dituliskan sebagai Berikut.

$$x_i = [e(k), e(k-1), e(k-2)] \quad (2.4)$$

Berikut merupakan struktur neural network kontroller yang dirancang.



Gambar 3. Struktur Direct Control Neural Network

Pada propagasi maju, output hidden layer  $j$  merupakan fungsi aktivasi dari jumlahan bobot neuron sebelumnya dan dapat dirumuskan sebagai Berikut [4].

$$h_j = \frac{1}{1 + e^{-S_j}} \quad (2.5)$$

$$S_j = \sum_{i=1}^t w_{ji} x_i$$

Dengan cara yang sama keluaran neuron output layer sebagai sinyal kontrol dapat ditentukan.

$$u = \frac{1}{1 + e^{-r}} \quad (2.6)$$

$$r = \sum_{j=1}^t v_j h_j$$

Proses learning neural network akan meminimalisasi cost function berupa integral square error.

$$E(t) = \frac{1}{2} \sum_{k=1}^t e_y(k)^2 \quad (2.7)$$

$$e_y = y_{ref} - y$$

Minimisasi cost dilakukan terhadap weight  $w_{ji}$  dan  $v_j$ . Menggunakan aturan rantai diperoleh minimisasi cost function terhadap weight output [5]

$$\frac{\partial E(t)}{\partial v_j} = \frac{\partial E(t)}{\partial e_y} \frac{\partial e_y}{\partial u(t)} \frac{\partial u(t)}{\partial r} \frac{\partial r}{\partial v_j}$$

Local gradien output layer ditentukan sebagai  $\delta^1$

$$\delta^1 = \frac{\partial E(t)}{\partial e_y} \frac{\partial e_y}{\partial u(t)} \frac{\partial u(t)}{\partial r} \frac{\partial r}{\partial v_j}$$

$$\delta^1 = e_y u(t) [1 - u(t)] \quad (2.5)$$

$$\frac{\partial E(t)}{\partial v_j} = -\delta^1 * h_j * \frac{\partial e_y}{\partial u} \quad (2.6)$$

Updating weight  $v_j$ :

$$\Delta v_j = -\eta * \frac{\partial E(t)}{\partial v_j} \quad (2.5)$$

$$v_j(t+1) = v_j(t) + \eta \text{sign} \left( \frac{\partial e_y}{\partial u} \right) \delta^1 h_j \quad (2.6)$$

Dengan menggunakan cara yang sama, diperoleh minimisasi cost function terhadap weight hidden.

$$\frac{\partial E(t)}{\partial w_{ji}} = -\delta^1 v_j h_j (1 - h_j) x_i \frac{\partial e_y}{\partial u}$$

Local gradient hidden layer ditentukan sebagai  $\delta^2$

$$\delta_j^2 = \delta^1 v_j h_j (1 - h_j) \quad (2.7)$$

$$\frac{\partial E(t)}{\partial w_{ji}} = -\delta_j^2 x_i \frac{\partial e_y}{\partial u} \quad (2.8)$$

Updating weight  $w_{ji}$ :

$$\Delta w_{ji} = \eta * \frac{\partial E(t)}{\partial w_{ji}} \quad (2.9)$$

$$w_{ji}(t+1) = w_{ji}(t) + \eta \text{sign} \left( \frac{\partial e_y}{\partial u} \right) \delta_j^2 x_i \quad (2.10)$$

Learning rate selain dapat diperoleh melalui metode experimental, dapat pula dibuat dinamis sesuai nilai error melalui self tuning [6]. Adaptif learning rate seperti ini dapat dirumuskan sebagai persamaan Berikut.

$$\eta' = \eta + \alpha \text{abs}(e_y) \quad (2.11)$$

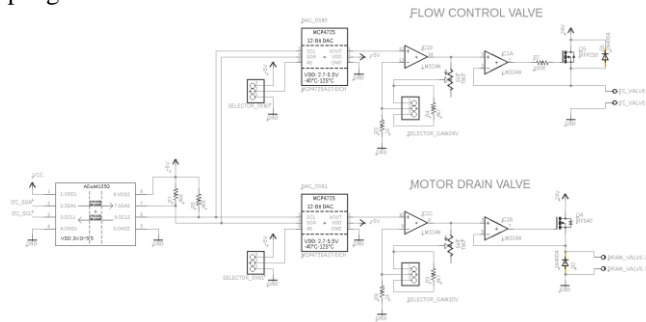
Learning rate  $\eta$  awal dapat digunakan sangat kecil dan  $\alpha$  dapat dipilih berdasarkan eksperimen tanpa ada masalah.

### E. Perancangan Hardware Tertanam

Mikrokontroller merupakan unit pemrosesan digital untuk

melaksanakan suatu tugas spesifik dalam sistem tertanam. Mikrokontroler STM32F407VGT6 melaksanakan fungsi pembacaan sensor dengan ADC dan memberikan sinyal kontrol ke aktuator. Berikut merupakan rancangan mikrokontroler dan modul komunikasi dengan PC.

Pembacaan tegangan sensor 0-10V perlu diturunkan melalui rangkaian voltage divider agar menjadi 0-3.3V. Modul power electronic sebagai controlling device berupa motor flow control valve dan motor drain valve menggunakan modul DAC MCP4725 yang dikuatkan oleh opamp dan mosfet regulator. Berikut merupakan rangkaian penguatan untuk kedua aktuator ini.




Gambar 4. Rangkaian Controlling Device

#### F. Skenario Pengujian Kontroller

Pengujian kontroller dilakukan pada software Simulink untuk mendapatkan model kontroller dengan spesifikasi respon terbaik. Kondisi nominal yang digunakan pada tahap pengujian diantaranya:


- Masukin flow rate  $Q_{in}$ : 0 – 3 lt/min
- Tegangan pompa konstan 10VDC
- Range tegangan motor flow valve : 12VDC (full closed) – 22VDC (full open)
- Batas runtime sistem : 1400 detik
- Timesampling : 50ms
- Learning rate awal :  $10^{-5}$
- Set point level statis : 100mm
- Pembebanan nominal : manual drain valve full open

Sedangkan untuk kondisi pembebanan, divariasikan bukaan valve dengan step 25% naik lalu turun seperti pada diagram sekuen berikut.



Gambar 5. Urutan Beban Bukaan Motor Drain Valve

Untuk kondisi tracking, divariasikan set point dengan step 50mm naik dan turun seperti kurva sinyal tracking Berikut.




Gambar 6. Urutan Setpoint untuk Pengujian Tracking

### III. PENGUJIAN KONTROLLER

Pengujian kontroller meliputi pengujian hardware dan algoritma program. Pengujian hardware meliputi pembacaan sensor dan rangkaian controlling device. Sedangkan pengujian algoritma kontrol meliputi pengujian berbeban tanpa kontroller, kontroller dengan learning rate konstan, kontroller dengan learning rate adaptif, serta tracking set point pada beban konstan 50%.

#### A. Pengujian Pembacaan Sensor

Pengujian ini dilakukan dengan memberi tegangan referensi dari modul DAQ terkalibrasi ke 2 pin ADC STM32 (AI), yakni sensor flow dan level. Sinyal uji yang digunakan ialah ramp dengan pola naik lalu turun. Gambar berikut menunjukkan tegangan pembacaan linier terhadap tegangan referensi yang diberikan.




Gambar 7. Pembacaan Analog Input Sinyal Referensi

Bentuk linier diperoleh karena tegangan masukan ADC diturunkan menggunakan resistor yang memiliki karakteristik beban linier. Simpangan tersebut dianggap tidak memengaruhi pembacaan sensor karena sangat kecil bila dibandingkan range sinyal maksimal yang dapat dibaca, yakni 10V. Simpangan maksimum ADC diperoleh sebesar 121.6mV.

#### B. Pengujian Power Electronics

Rangkaian controlling device yang telah dibuat diuji dengan memberikan tegangan ke pin analog input modul DAQ terkalibrasi. Gambar Berikut menunjukkan respon linier tegangan kontrol yang diberikan.




Gambar 8. Pembacaan Sinyal Kontrol Motor Drain Valve

Simpangan maksimum terhadap pembacaan AI DAQ diperoleh sebesar 489mV untuk rangkaian penguatan flow control valve dan 200mV untuk rangkaian penguatan drain valve. Bentuk linier pada sinyal ramp uji diakibatkan oleh penguatan non-inverting operational amplifier yang merupakan nilai scalar konstan karena merupakan susunan resistor. Dengan penambahan rangkaian voltage follower, sinyal yang dikuatkan menuju beban akan dikoreksi oleh feedback yang berasal dari tegangan source mosfet.

### C. Pengujian Berbeban tanpa Kontroller


Pengujian ini menunjukkan respon level dipengaruhi oleh beban bukaan valve dan tidak bisa mencapai referensi set point. Respon level yang diperoleh tidak stabil, membuktikan bahwa perlu adanya kontroller agar set point dapat dicapai seperti ditunjukkan gambar Berikut.



Gambar 9. Respon Level tanpa Kontroller

### D. Pengujian Berbeban Kontroller dengan Learning Rate Konstan

Pada pengujian ini digunakan set point level tetap sebesar 100mm dan variasi learning rate konstan, yaitu 0.001, 0.01, 0.1, 1, 2, 5, dan 10. Pada pengujian berbeban dan variasi learning rate konstan, diperoleh hasil bahwa learning rate kurang dari 0.1 memiliki square error steady state yang tinggi. Pada kondisi ini respon level mengalami underfitting, yakni kejadian dimana model neural network tidak mempelajari hubungan variable dalam data dengan baik. Underfitting ini dipengaruhi oleh learning rate yang terlampau kecil sehingga model tidak dapat melakukan update weight dengan cepat. Perubahan weight yang lama menyebabkan settling time 5% tidak dapat tercapai. Cost function square error yang terus meningkat namun updating weight yang tetap lambat menyebabkan respon level terus meningkat pula.



Gambar 10. Respon Pembebanan dengan Lr Konstan

Apabila melihat dari pola persen overshoot dan indeks square error, keduanya semakin kecil saat learning rate dinaikkan. Model yang mengikuti set point ialah neural network dengan learning rate 0.1, 1, 2, 5, dan 10, tetapi masih terdapat overshoot 7.4% hingga 24%. Learning rate 0.1 memiliki overshoot kedua Model neural network dengan learning rate sebesar 5 merupakan model terbaik pada pengujian ini, dimana memiliki persen overshoot terkecil sebesar 7.408% dan square error  $6.222 \times 10^7$  namun tidak dapat mencapai tujuan settling time  $< 90$  detik. Oleh sebab itu, Langkah penentuan learning rate dengan cara eksperimental seperti ini berpotensi memiliki respon overshoot yang besar.


Dari pengujian berbeban dan learning rate konstan diatas spesifikasi settling time, persen overshoot, dan nilai steady state diperoleh seperti tabel Berikut.

Tabel 1.

No.	$\eta_{konstan}$	$t_s(5\%)$ (detik)	Overshoot (mm)	% overshoot	$y(\infty)$
1	0.001	$\infty$	128.07	28.07%	$\infty$
2	0.01	$\infty$	127.732	27.732%	$\infty$
3	0.1	1056.2	124.408	24.408%	100
4	1	289.748	120.739	20.739%	100
5	2	140.761	119.584	19.584%	100
6	5	97.6714	107.408	7.408%	100
7	10	98.7054	107.473	7.473%	100

### E. Pengujian Berbeban Kontroller dengan Adaptasi Learning Rate

Pada pengujian ini digunakan set point level tetap sebesar 100mm dan diberikan variasi nilai alpha (parameter adaptasi learning rate) sebesar 0.0001, 0.001, 0.01, 0.1, dan 1. Respon hasil pengujian tampak pada gambar di bawah.



Gambar 11. Respon Pembebanan dengan Adaptasi Lr


Pada  $\alpha < 1$ , tampak bahwa semakin kecil alpha menyebabkan persen settling time 5%, overshoot, dan indeks ISE semakin besar. Model neural network terbaik dalam pengujian ini ialah  $\alpha = 0.1$  dimana overshoot dicapai paling kecil sebesar 2.887%, ISE  $6.2136 \times 10^7$ , dan settling time 5% sebesar 85.3252 detik. Persen overshoot yang diperoleh dengan adaptasi learning rate oleh alpha diperoleh lebih kecil daripada tanpa adaptasi alpha. Hal ini disebabkan alpha dapat menyesuaikan learning rate berdasarkan error respon level. Langkah eksperimental pemilihan alpha sebaiknya dimulai dari  $\alpha < 1$  dan berangsur-angsur turun dengan melihat persen overshoot. Step penurunan sepersepuluh seperti pada pengujian ini dapat digunakan karena pergerakan trend overshoot, settling time, dan ISE dapat lebih terlihat.



Tabel 2.  
Spesifikasi Respon pada Pembebanan saat Adaptasi Lr


No.	alpha	$t_s$ (5%) (detik)	Overshoot (mm)	% overshoot	$y(\infty)$
1	0.0001	306.274	122.167	22.167%	100
2	0.001	101.469	108.828	8.828%	100
3	0.01	89.375	104.523	4.523%	100
4	0.1	85.3252	102.887	2.887%	100
5	1	97.65	104.729	4.729%	100

Pada pengujian variasi alpha ini, respon level memiliki karakteristik peningkatan overshoot saat  $\alpha \geq 1$ . Peningkatan nilai error dimana maksimal 10V jika tidak dikurangi melalui perkalian dengan alpha sebagai factor adaptasi, menyebabkan learning rate terus menerus naik. Learning rate yang tinggi menyebabkan model neural network sangat adaptif dan learning berlangsung cepat. Proses learning yang terlalu cepat ini menyebabkan respon level stabil terhadap beban bukaan valve akibat updating weight yang cepat pula. Perubahan weight yang cepat juga menyebabkan keluaran neuron output layer berubah-ubah secara signifikan. Hal ini tampak pada sinyal keluaran controller, yakni sinyal kontrol flow valve yang memiliki pertambahan periode osilasi seiring peningkatan alpha. Kejadian ini dinamakan overfitting, yakni model melakukan learning terlalu baik dengan learning rate yang besar. Meskipun sudah memenuhi overshoot < 5% dan ISE yang rendah pada sinyal uji, osilasi sinyal kontrol dalam prakteknya dihindari karena berpotensi merusak actuator. Gambar di bawah menunjukkan sinyal kontrol keluaran dari controller NN.



Gambar 12. Respon Sinyal Kontrol dengan Adaptasi Lr saat Pembebanan


Proses learning yang terjadi pada pengujian ini berdampak pada pengurangan efek pembebanan pada controlled variable level. Pada kurva pembebanan kedua, yakni pada detik ke-240 beban bertambah ke 50%. Level air mengalami penurunan berupa undershoot. Namun penurunan ini tidak signifikan dan dapat diabaikan karena undershoot kecil, yaitu maksimal 0.2563% dalam sampel pengujian. Pembebanan ketiga dan selanjutnya, efek undershoot ini tidak tampak karena proses learning dapat mengurangi efek undershoot yang terjadi agar tetap steady.



Gambar 13. Respon Undershoot Beban dengan Adaptasi Lr

## F. Pengujian Beban 50% terhadap Tracking Set Point

Pengujian ini bertujuan untuk mengetahui respon sistem bila diberikan perubahan step sinyal set point. Pola yang dicoba ialah kenaikan dan penurunan sebesar 25mm selama pembebanan 50% motor drain valve terbuka. Pengujian ini meliputi pengujian tracking terhadap variasi learning rate konstan dan learning rate adaptif (berubah). Berikut merupakan respon tracking level dengan learning rate konstan.




Gambar 14. Respon Tracking dengan Lr Konstan

Pada pengujian tracking set point, model neural network melakukan learning dengan mengambil sinyal error untuk updating weight. Ketika step naik, diperoleh error positif, yang menyebabkan weight model meningkat. Weight ini akan memicu neuron output layer untuk memberikan keluaran sinyal kontrol lebih besar untuk mencapai set point yang baru. Berdasarkan tabel perbandingan diatas, semakin besar learning rate membuat model neural network lebih cepat beradaptasi dengan settling time 5% yang kecil dan persen overshoot yang kecil pula. Learning rate yang terlalu kecil, seperti learning rate 0.001 dan 0.01 menyebabkan model neural network tidak bisa melakukan tracking sinyal referensi atau set point. Kegagalan tracking ini disebabkan oleh perubahan weight yang kecil sedangkan plant level membutuhkan sinyal kontrol yang lebih besar. Model terbaik untuk pengujian ini ialah learning rate sebesar 10, dengan settling time terkecil 64.815 detik, overshoot 4.7544%, dan indeks ISE terkecil, yakni  $10.092 \times 10^7$ .

Tabel 3.  
Spesifikasi Respon saat Tracking pada Lr Konstan

No.	$\eta_{konstan}$	$t_s$ (5%) (detik)	Overshoot (mm)	% overshoot	$y(\infty)$
1	0.001	$\infty$	-	-	76.62
2	0.01	$\infty$	-	-	72.3
3	0.1	119.94	67.774	17.8	48.35
4	1	80.3123	59.5316	9.5	50
5	2	68.636	57.5939	7.6	50
6	5	66.25	55.7571	5.7	50
7	10	64.815	54.7544	4.7	50

Berdasarkan Langkah pengujian ini, penentuan learning rate yang memenuhi spesifikasi respon tertentu masih dilakukan secara eksperimental dengan memilih learning rate yang tinggi, tetapi masih beresiko terjadinya overfitting. Oleh sebab itu, pada pengujian tracking set point ini juga dicoba adaptasi learning rate menggunakan alpha. Untuk mengetahui respon level saat learning rate berubah (adaptif) dilakukan dengan variasi nilai alpha sebesar 0.0001, 0.001, 0.01, 0.1, dan 1. Pengujian ini dilakukan untuk mengetahui respon sistem dengan adanya adaptasi learning rate terhadap perubahan set point.



Gambar 15. Respon Tracking dengan Adaptasi Lr

Berdasarkan tabel spesifikasi setpoint step pertama 50mm tersebut, semakin besar alpha berakibat penurunan persen overshoot, settling time, dan indeks ISE. Persen overshoot didapatkan lebih kecil dibandingkan pengujian dengan learning rate konstan (overshoot terkecil 4.7544% pada tracking pertama learning rate konstan). Selain itu, settling time juga diperoleh lebih cepat dibandingkan pengujian learning konstan (sampel tercepat 64.815 detik). Penggunaan metode adaptasi learning rate tidak menghasilkan adanya kegagalan tracking seperti pengujian sebelumnya, karena learning rate terus diupdate agar perubahan weight neuron juga semakin cepat. Keberhasilan tracking tampak pada gambar diatas, membuktikan semua variasi alpha pada akhirnya mengikuti setpoint.

Untuk melihat proses learning pada tracking selanjutnya, ditinjau nilai persen overshoot pada step 100mm yang tersaji dalam tabel berikut. Dibandingkan persen overshoot step tracking pertama (50mm), tracking kedua memiliki persen overshoot yang lebih kecil untuk tiap variasi alpha.

Tabel 4.

Spesifikasi Respon saat Tracking pada Adaptasi Lr

No.	alpha	$t_s$ (5%) (detik)	Overshoot (mm)	% overshoot	$y(\infty)$
1	0.0001	-	67.5299	17.5299	-
2	0.001	94.3237	61.3994	11.3994	50
3	0.01	62.2709	55.9858	5.9858	50
4	0.1	55.8532	53.1362	3.1362	50
5	1	50.803	51.8227	1.8227	50

Berdasarkan tabel spesifikasi setpoint step pertama 50mm tersebut, semakin besar alpha berakibat penurunan persen overshoot, settling time, dan indeks ISE. Persen overshoot didapatkan lebih kecil dibandingkan pengujian dengan learning rate konstan (overshoot terkecil 4.7544% pada tracking pertama learning rate konstan). Selain itu, settling time juga diperoleh lebih cepat dibandingkan pengujian learning konstan (sampel tercepat 64.815 detik). Penggunaan metode adaptasi learning rate tidak menghasilkan adanya kegagalan tracking seperti pengujian sebelumnya, karena learning rate terus diupdate agar perubahan weight neuron juga semakin cepat. Keberhasilan tracking tampak pada gambar diatas, membuktikan semua variasi alpha pada akhirnya mengikuti setpoint. Model terbaik untuk mendapat persen overshoot terkecil dengan osilasi kecil yakni  $\alpha=0.01$ . Model ini memiliki persen overshoot 5.9858% dan settling time 62.2709 detik pada step tracking pertama.

#### IV. KESIMPULAN

Modul ADC dari kontroller tertanam memberikan hasil yang linear dengan kesalahan pembacaan maksimal sebesar 121.6mV. Modul controlling device untuk flow valve dan

motor drain valve memiliki karakteristik linier dengan kesalahan masing-masing 489mV dan 200mV. Pengujian tanpa kontroller menunjukkan respon level dipengaruhi oleh beban motor drain valve dan tidak dapat mencapai set point. Kontroller direct neural network dengan learning rate sebesar 5 memiliki hasil terbaik dari sampel uji learning rate konstan, mampu beradaptasi dengan beban motor drain valve dengan overshoot 7.408% dan 5.7571% saat tracking set point. Namun, settling time 5% saat pembebanan 97.6714 detik, diatas settling time 5% yang Diharapkan selama 90 detik. Kontroller direct neural network dengan adaptasi learning rate dengan  $\alpha=0.01$  memiliki respon terbaik dari sampel uji adaptasi learning rate, yang memenuhi settling time kurang dari 90 detik, yaitu 89.375 detik saat pembebanan dan 62.2709 detik saat tracking set point. Selain itu terdapat overshoot 4.523% saat pembebanan dan 5.9858% saat tracking set point. Penggunaan metode eksperimental dengan mencari learning rate konstan yang cocok dengan spesifikasi overshoot dan settling time cukup menyulitkan karena harus menjalankan model sistem berulang kali. Self tuning learning rate terhadap error dengan parameter alpha dilakukan untuk mendapatkan respon yang diinginkan dengan cepat (overshoot < 10% dan settling time 5% < 90 detik).

#### DAFTAR PUSTAKA

- [1] Bytronic, "Process Control Technology PCT-100 Datasheet," 2015. Accessed: Dec. 11, 2022. [Online]. Available: <http://www.bytronic.net/wp-content/uploads/2015/04/PCT100-PL0214.pdf>
- [2] M. Short and A. A. Selvakumar, "Non-Linear Tank Level Control for Industrial Applications," *Appl Math (Irvine)*, vol. 11, no. 09, pp. 876–889, 2020, doi: 10.4236/am.2020.119057.
- [3] I. P. Jakoubek, "Experimental Identification of Stable Nonoscillatory Systems from Step-Responses by Selected Methods."
- [4] S. S. Haykin and S. S. Haykin, *Neural networks and learning machines*. Prentice Hall/Pearson, 2009.
- [5] R. Hernández-Alvarado, L. G. García-Valdovinos, T. Salgado-Jiménez, A. Gómez-Espinosa, and F. Fonseca-Navarro, "Neural network-based self-tuning PID control for underwater vehicles," *Sensors (Switzerland)*, vol. 16, no. 9, Sep. 2016, doi: 10.3390/s16091429.
- [6] A. Noriega Ponce, A. Aguado Behar, A. Ordaz Hernández, and V. Rauch Sitar, "Neural Networks for Self-tuning Control Systems," *Acta Polytechnica*, vol. 44, pp. 49–52, 2004, [Online]. Available: <http://ctn.cvut.cz/ap/>